湖南工学院2027届毕业设计（论文）课题任务书

学院：计算机科学与工程学院　　专业：数据科学与大数据技术

指导教师	桂友武	学生姓名	陈嘉乐
课题名称	基于混合检索与上下文增强的RAG知识库问答系统设计与实现		

	1. 行业调研与文献回顾。梳理国内在线音乐平台的发展现状与竞争格局，了解网易云音乐以歌单与乐评社区为核心的差异化运营模式；系统回顾用户分群、聚类分析与音乐用户行为研究的相关文献，重点理解 K-Means 及其改进算法的原理，以及聚类有效性的评价方法，为课题研究奠定理论基础。 2. 数据获取。以网易云音乐为研究对象，通过平台公开页面与接口采集歌单及用户公开数据，包括歌单名称、标签、曲风、曲目数量、播放量、收藏量、评论量、创建时间，以及歌单创建者的公开主页信息，如创建歌单数、粉丝数、关注数等；明确采集范围与时间窗口，控制采集频率，仅使用公开数据，不涉及用户身份等隐私信息。 3. 数据预处理。对原始数据进行去重、缺失值处理与异常值识别，剔除曲目数为零、标签严重缺失以及批量生成的无效歌单；统一曲风与标签的表述，合并同义标签；针对播放量、收藏量等呈长尾分布的变量作对数变换，并在量纲统一后进行标准化处理。 4. 特征工程。从用户维度构建反映音乐消费结构与行为强度的特征，主要包括活跃度（创建歌单数、动态数）、影响力（粉丝数、歌单被收藏量）、内容偏好结构（各曲风歌单占比、曲风多样性熵值）与消费深度（平均单歌单曲目数、评论互动率）等；通过相关性分析与主成分分析剔除冗余特征，形成用于聚类的低维特征集。 5. 用户分群。采用 K-Means 算法对用户样本进行聚类，以肘部法则结合轮廓系数和 Calinski-Harabasz 指数确定最优聚类数，并通过多次随机初始化检验聚类结果的稳定性；结合各簇的中心特征与雷达图，对群体进行命名与画像描述，如深度乐迷型、歌单策展型、流行跟随型与低频尝鲜型等。 6. 歌单风格偏好差异分析。以簇为单位统计各群体歌单的曲风分布，采用卡方检验分析不同用户群体在曲风结构上的差异显著性，采用单因素方差分析比较各群体在曲风多样性、歌单规模与互动水平等指标上的均值差异；结合对应分析与可视化，刻画各群体在“曲风—场景—情绪”标签组合上的偏好模式。 7. 结论与建议。总结用户分群结构与风格偏好差异的主要发现，从个性化推荐、歌单运营、新用户冷启动与版权采购等方面提出差异化运营建议，并说明研究的局限与后续改进方向。

拟达到的要求或技术指标	1.理论理解。掌握 K-Means 聚类的基本原理、距离度量方式与聚类有效性评价指标，理解用户分群在音乐流媒体平台运营中的应用逻辑。 2.数据处理能力。能够独立完成数据采集、清洗与特征构建，妥善处理长尾分布、标签不规范、样本不均衡等实际问题，形成可复用的数据处理流程。 3.建模与分析技能。能够合理确定聚类数目，对聚类结果进行稳定性检验与业务解释，并能运用卡方检验、方差分析等方法对群体差异进行统计检验。 4.可视化与解释。能够运用雷达图、热力图、散点图等形式清晰地呈现分群结构与偏好差异，从数据中提炼具有业务价值的结论。 5.报告撰写。能够撰写结构清晰、逻辑严谨、论据充分的毕业论文，且图表规范，参考文献引用准确。 6.技术指标。有效样本规模不少于 3000 个歌单和 1500 名用户；聚类结果的轮廓系数不低于 0.25，各簇样本占比不低于 5%；群体差异检验的显著性水平取 0.05，主要结论均通过统计检验。
进度安排起止日期和进度安排工作内容	2026.10.8-2026.10.31 课题审核、学生选题 2026.11.1-2026.11.20 任务内容确定，课题任务书的下达确认及前期调研 2026.11.21-2027.1.20 课题分析、方案论证、撰写毕业设计开题报告、答辩及提交 2027.1.21-2027.3.29 熟悉开发工具，进行系统设计与实现，撰写设计说明书初稿 2027.3.30-2027.4.5 中期检查 2027.4.6-2027.4.22 按照中期检查完善论文及设计，提交答辩前的设计与论文 2027.4.23-2027.5.31 指导老师审阅、毕业设计查重、盲审、修改 2027.6.1-2027.6.7 参加毕业答辩，进一步修改毕业设计，提交电子稿材料定稿版

主要参考文献	[1]吴江,刘涛,刘洋.在线社区用户画像及自我呈现主题挖掘——以网易云音乐社区为例[J].数据分析与知识发现,2022,6(7):56-69.DOI:10.11925/infotech.2096-3467.2021.1449. [2]刘渊晨,王昊,高亚琪.在线音乐歌单播放量预测及影响因素分析[J].数据分析与知识发现,2021,5(8):100-112.DOI:10.11925/infotech.2096-3467.2020.1013. [3]王海龙,柳林,林民,等.基于信息检索及 k 均值聚类的音乐个性化推荐算法[J].吉林大学学报(工学版),2021,51(5):1845-1850.DOI:10.13229/j.cnki.jdxbgxb20200243. [4]殷丽凤,路建政.基于特征分箱和 K-Means 算法的用户行为分析方法[J].云南民族大学学报(自然科学版),2024,33(2):251-257. [5]李玥,穆维松,褚晓泉,等.基于改进量子粒子群的 K-means 聚类算法及其应用[J].控制与决策,2022,37(4):839-850.DOI:10.13195/j.kzyjc.2020.1302. [6]季铎,刘云钊,彭如香,等.基于主题词向量中心点的 K-means 文本聚类算法[J].计算机应用与软件,2024,41(10):282-286,318.DOI:10.3969/j.issn.1000-386x.2024.10.042. [7]白钊,王神武,王梦杨.基于改进 RFM 模型与聚类算法的民航客户细分研究[J].科技和产业,2023,23(19):200-203. [8]陈梁.基于特征提取和文本挖掘的数字音乐用户画像与专辑销量预测研究[D].广州:华南理工大学,2023. [9]黄春怡.QQ 音乐平台用户信息行为相关性研究[D].贵阳:贵州财经大学,2025.

教研室意见	选题符合本专业人才培养目标，体现本专业基本教学内容，内容任务目标明确，要求　技术指标具体，进度合理，能使学生受到　面综合实践训练，有利于培养学生独立解决实际问题的工作能力，同意下发。 2026 年 10 月 18 日